

陈景涛 | 大模型/Agent 研发工程师 | 3年工作经验

联系方式: 15688837985 | chen_jingtao@126.com | wx: jingtaoonline 意向岗位: 大模型/Agent 研发工程师

个人定位

3 年美团后端研发经验, 近期聚焦大模型 Agent 工程落地, 负责小团本地生活 Agent 的上下文工程、Skill 渐进式披露、记忆压缩、知识库链路、业务接入和开放平台建设。具备复杂业务链路抽象、平台化能力建设和高并发链路优化经验, 能从业务接入、上下文、数据链路和调试诊断等层面推动 Agent 能力工程化落地。

教育背景

山东大学 | 软件工程 本科 | 2019.9 - 2023.7

核心技能

Agent 工程: 熟悉 Agent 上下文工程、Tool/MCP 集成、Workflow 编排、RAG、记忆压缩、Prompt 模板化、实验分流和 Skill 平台化建设。

Java 后端: 熟悉 Java/Spring 生态, 具备异步任务、缓存、多级降级、链路治理、DAG 编排、复杂业务建模和性能优化经验。

平台化与 AI Coding: 擅长从重复业务需求中抽象通用协议、配置化能力和调试工具; 深度使用 Claude Code 等工具完成需求分析、前后端开发、单测编写和工程交付。

工作经历

美团 | 2023.7 - 至今

小团本地生活 Agent | 2025.10 - 至今

项目核心开发者，重点负责上下文工程、业务接入、工具维护、开放平台能力建设和 Agent 工程链路落地。

主导小团 Agent2.0 上下文工程重构：Token 消耗降低 70% (2025.12 - 2026.4)

背景问题：小团 Agent 接入美团 10+ 垂类业务后，Prompt 和业务知识快速膨胀，单轮请求存在大量无关 Skill、冗余历史上下文和重复业务说明；高峰 QPS 扩大 10 倍以上后，Token 成本、推理资源消耗和业务迭代效率成为主要瓶颈。

核心工作：

1. 主导设计 Skill 渐进式披露链路，将 Skill 拆为 summary / activation condition / full instruction / tool schema 等信息层级；首轮上下文仅注入摘要+路由信息，模型命中意图后再通过 tool call 拉取完整 Skill 内容。
2. 重构上下文构建链路，废弃大而全 Prompt，将上下文拆成基础设定、业务自定义、技能区和对话区；基于 FreeMarker 模板按业务、模型、实验分组、Skill 版本动态渲染，支持不同模型和灰度实验下快速切换上下文策略。
3. 参与建设入口网关意图分流能力，结合规则匹配和小模型/SLM 判断请求类型；简单意图绕过多步 Agent Tool/Workflow 推理，直接走传统搜索 + 单次大模型总结链路，复杂意图提前预加载相关 Skill。
4. 落地短期记忆压缩机制，基于 context 使用量阈值触发异步压缩和滚动摘要；按可重建性优先裁剪中间推理过程、搜索结果和工具执行结果，将历史多轮对话压缩为结构化摘要，保留当前目标、已确认结果、拒绝选项、偏好约束和待处理事项。
5. 参与长期记忆提取与注入链路设计，会话结束后异步提取结构化偏好和语义偏好；结构化信息通过槽位存储，语义偏好提炼为自然语言片段并向量化存储，会话开始时结合意图识别和当前 query 检索相关记忆，并控制注入 token 上限。
6. 参与建设知识库接入链路，支持文档清洗、分片、预览、索引入库和召回调试；实现结构化数据离线 pipeline，定时调度商家、供给、运营配置等数据导入索引库，减少业务知识手工维护成本。
7. 参与建设多级缓存策略，围绕 query 归一化、地理位置、业务类型、实验版本等维度构建缓存 key，支撑热点请求复用、限流兜底和高峰期降本。
8. 设计实现参数化实验能力，基于实验分流动态下发模型、Prompt、Skill 版本、预加载策略和降级策略，使业务方可以按实验组验证效果，而不是依赖代码发布完成策略切换。

结果产出：Agent2.0 全量上线后，整体 Token 消耗降低 70%，业务需求迭代效率提升 30%，badcase 率降低 5%，用户 7 天留存率提升 8%。

负责 AgentOS 业务接入与开放平台建设：10+ 业务线接入实现配置化 (2025.10 - 至今)

背景问题：小团 Agent 需要持续接入多个美团业务线，早期存在独立开发、协议不统一、调试链路分散、上线依赖研发的问题，难以支撑规模化接入。

核心工作：

1. 从 0 到 1 实现 Agent 业务接入全链路，覆盖上下文构建、tool 调用、workflow 编排、模型输出解析、数据接入、卡片渲染和消息推送。
2. 抽象统一业务接入协议，将欢迎语、推荐问、AI 技能、运营干预、消息更新等高频场景沉淀为平台配置，减少业务侧重复开发。
3. 打通主 Agent 服务与开放平台，完成 Skill 从创建、调试、预览、实验配置到上线的完整通路，提升业务方自助接入和灰度验证效率。
4. 建设统一消息能力，支持消息强插、消息修改、消息推送更新等通用功能，支撑不同业务线复用同一套触达和渲染链路。

结果产出：支持小团接入美团主流 10+ 业务线，多数通用接入需求可通过配置完成，显著缩短业务接入和迭代周期。

美团 App 首页推荐工程 | 2023.7 - 2025.10

项目核心开发者，负责推荐链路模块设计开发、架构设计、性能优化、调试诊断和工程治理。

推荐链路性能优化与工程治理 (2024.10 - 2025.8)

1. 推动首页推荐埋点治理，针对近 500 个历史埋点字段建设 Java 反射访问监控，识别字段使用情况和下游依赖；按裁剪字段、一般字段和重点字段分级治理，一般字段改为写 Kafka 到 Hive，降低主链路返回体积。
2. 负责渲染信息预调用优化，在直播、特团召回完成后由聚合服务异步推送候选结果给渲染服务，提前调用渲染信息接口并写入 Guava 本地缓存；重点处理异步时序、缓存 key、有效期和未命中兜底。
3. 建设请求 Mock 与调试回放能力，支持请求日志采集、gzip 压缩、traceId 回放、实验加白、debug 信息透出和强插供给，将 badcase 排查流程沉淀为多团队复用工具。
4. 参与首页推荐渲染服务技术重构，将渲染服务拆分为 IO、渲染算子、数据映射 3 层，设计统一路由映射、DAG 执行图、字段粒度算子和注解约束机制。

结果产出：推荐接口端到端耗时分别降低 140ms / 40ms，badcase 排查从小时级降低到分钟级，渲染服务重构后需求开发效率提升 30%+。