

陈景涛 | 大模型/Agent 研发工程师 | 3年工作经验

联系方式: 15688837985 | chen_jingtao@126.com | wx: jingtaoonline

意向岗位: 大模型/Agent 研发工程师

个人定位

3 年美团后端研发经验, 近期聚焦大模型 Agent 工程落地, 负责小团本地生活 Agent 的上下文工程、Skill 渐进式披露、记忆压缩、知识库链路和开放平台建设。

具备复杂业务系统抽象、平台化能力建设和高并发链路优化经验, 曾在首页推荐、渲染服务、调试回放平台等核心链路中承担模块设计、核心开发和上线推进工作。

深度使用 AI Coding 完成业务系统从需求分析、前后端开发、单测到上线的完整闭环, 并沉淀 Skill 复用、上下文组织和编码工作流程经验。

教育背景

山东大学 | 软件工程 本科 | 2019.9 - 2023.7

核心技能

Agent 工程落地: 熟悉 Agent 系统工程化落地, 具备 Spring AI、Tool/MCP 集成、Workflow 编排、上下文工程、RAG、记忆压缩、Prompt 模板化等实践经验。

上下文工程与 Skill 架构: 主导设计渐进式披露 Skill 架构, 通过预加载、规则裁剪、全局摘要、按需激活、模板化渲染和动态参数下发降低上下文成本并提升业务迭代效率。

Java 后端与分布式系统: 熟悉 Java/Spring 生态, 具备高并发接口优化、异步任务、缓存、链路治理、DAG 编排、复杂业务链路设计与性能优化经验。

平台化与工程架构: 擅长从业务需求中抽象通用协议和平台能力, 推动业务接入、配置化开发、调试诊断、数据 pipeline 等能力沉淀。

AI Coding 工作流: 深度使用 Claude Code 等工具完成前后端系统开发、单测编写、内网文档检索和工程交付, 并沉淀可复用 Skill 和编码流程。

工作经历

美团 | 2023.7 - 至今

小团本地生活 Agent | 2025.10 - 至今

角色定位：项目核心开发者，重点负责上下文工程设计、业务接入、工具维护、开放平台能力建设和 Agent 工程链路落地。

工作重点：围绕小团本地生活 Agent 的多业务接入、上下文治理、Skill 架构、知识库、记忆压缩和开放平台建设，推动 Agent 能力从单点业务实现演进为可配置、可扩展、可复用的平台化能力。

主导小团 Agent2.0 上下文工程重构：Token 消耗降低 70% (2025.12 - 2026.4)

角色定位：上下文工程模块负责人，主导 Skill 渐进式披露、Prompt 模板化、记忆压缩和知识库接入链路设计与落地，协同入口网关、实验分流和业务接入模块完成整体重构上线。

背景问题：小团 Agent 持续接入美团 10+ 垂类业务后，上下文快速膨胀，业务知识维护分散；高峰 QPS 扩大 10 倍以上后，Token 成本、资源消耗和模块协同效率成为主要瓶颈。

核心工作：

1. 设计渐进式披露 Skill 架构：基础设定、通用 Skill 和预加载 Skill 初始注入，其他垂类 Skill 仅注入 summary，由模型根据意图通过 tool call 按需激活加载。
2. 重构上下文构建链路：废弃大而全 Prompt，拆分基础设定、业务自定义和技能区，使用 FreeMarker 模板结合实验参数动态渲染不同模型、业务和 Skill 版本的上下文。
3. 建设入口网关意图分流能力：结合规则匹配和小模型/SLM 判断，简单明确意图绕过模型推理，直接走传统搜索与大模型总结；复杂意图预加载相关技能。
4. 设计多级缓存策略：基于 query 相似度和地理位置多级粒度构建缓存，支撑高峰期限流和热点请求降本。
5. 落地记忆压缩机制：通过规则裁剪工具调用明细和冗余上下文，保留必要的全局摘要；通过标签配置和离线任务提取长期记忆。
6. 建设知识库链路：支持文档清洗、分片、预览、索引入库；同时实现结构化数据离线 pipeline，定时调度数据任务导入索引库。
7. 支持参数化实验：基于实验分流动态下发模型、Prompt、Skill 版本等参数，提升灰度验证和精细化迭代效率。

结果产出：Agent2.0 全量上线后，Token 消耗降低 70%，业务需求迭代效率提升 30%，badcase 率降低 5%，用户 7 天留存率提升 8%。

负责 AgentOS 业务接入与开放平台建设：10+ 业务线接入实现配置化 (2025.10 - 至今)

角色定位：业务接入与开放平台核心开发者，负责从 0 到 1 设计和实现 Agent 管理平台的通用接入链路，抽象业务协议和平台能力，支撑后续需求配置化完成。

背景问题：小团 Agent 需要持续接入多个美团业务线，若每个业务都定制开发，会导致能力重复建设、协议不统一、调试上线链路长，难以支撑快速规模化扩展。

核心工作：

1. 从 0 到 1 实现 Agent 业务接入全链路，覆盖上下文构建、tool 调用、workflow 编排、模型输出解析、数据接入、卡片渲染和消息推送。

2. 抽象统一协议规范，覆盖欢迎语、推荐问、AI 技能、运营干预等场景，降低不同业务线接入成本。
3. 建设统一消息能力，支持消息强插、消息修改、消息推送更新等通用功能，减少业务侧重复开发。
4. 打通主 Agent 服务与开放平台，完成 Skill 模块从创建、调试到上线的完整通路。
5. 将高频业务需求沉淀为平台配置能力，推动后续业务通过配置而非代码改动完成接入。

结果产出：支持小团接入美团主流 10+ 业务线，多数通用接入需求可通过配置完成，显著缩短业务接入和迭代周期。

负责小团供给信息萃取系统 AI Coding 落地：一周完成系统上线（2026.4 - 至今）

角色定位：系统核心开发者，负责使用 AI Coding 完成前端界面、后端接口、任务编排、状态流转、消息推送和单测建设，推动系统从需求到上线闭环落地。

背景问题：为提升供给推荐准确度，需要从一线 BD 拜访商家拍摄的实景视频中提取结构化信息，并融合美团商家信息、用户评论等数据生产优质内容数据。

核心工作：

1. 使用 Claude Code 完成前端界面、后端接口和单测编写，形成从任务提交到结果回流的完整业务链路。
2. 基于 Airflow 实现 DAG 多任务编排，支持视频处理、模型萃取、结果融合、数据导入等多阶段节点执行。
3. 设计任务状态流转和失败重试机制，覆盖任务提交、异步结果上报、状态变更、失败重试和数据入库。
4. 打通美团 IM 工具，实现消息推送和视频上传能力；借助 AI Coding 检索内网文档并完成接口接入。
5. 支持多阶段 Prompt 调试和应用上线，提升萃取质量和业务验证效率。

结果产出：一周内完成系统上线，目前已采样北京、上海两地 400+ 餐厅，支撑供给推荐内容生产链路验证。

美团 App 首页推荐工程 | 2023.7 - 2025.10

角色定位：项目核心开发者，负责推荐链路模块设计开发、架构设计、性能优化、调试诊断和工程治理。

工作重点：围绕首页推荐链路的性能、可维护性和调试效率，推动埋点治理、渲染链路优化、请求 Mock 回放和渲染服务重构，为后续复杂推荐业务迭代提供稳定工程基础。

推动推荐链路埋点治理与性能优化：端到端耗时降低 140ms（2025.8）

角色定位：埋点治理与性能优化核心推动者，负责监控建设、字段分级、下游协同、灰度放量 and 双写改造方案落地。

背景问题：首页推荐多年迭代积累近 500 个埋点字段，大量废弃字段长期未治理，埋点数据体积约占请求结果 30%，影响接口性能和链路成本；直接下线字段又存在下游兼容性风险。

核心工作：

1. 通过 Java 反射打点建设埋点使用情况监控大盘，识别字段访问情况和下游依赖。
2. 协同下游数据使用方梳理字段价值，对齐重点保留字段、废弃字段和技术变更节奏。
3. 将埋点字段划分为裁剪字段、一般字段和重点字段，分别制定下线、转存和保留策略。
4. 通过 1% 起步逐步灰度放量，出现异常及时回滚，降低字段治理对线上链路的影响。

5. 对重点字段保持原链路下发；一般字段不再下发到客户端，改为单独写 Kafka 到 Hive，业务方使用时通过联表查询。

结果产出：完成埋点字段治理后，首页推荐接口端到端耗时降低 140ms，同时降低返回体积和链路资源消耗。

负责推荐链路渲染信息预调用优化：接口耗时降低 40ms（2024.10 - 2024.12）

角色定位：渲染链路性能优化负责人，负责异步推送、预调用、缓存命中和全链路接入方案设计与落地。

背景问题：首页推荐聚合服务包含多路召回，其中直播、特团两路召回耗时较短，但召回结果返回渲染服务后，渲染服务再调用渲染信息接口耗时较长，成为整体链路瓶颈。

核心工作：

1. 调整召回与渲染链路协作方式，在直播、特团召回完成后，由聚合服务立即发起异步 HTTP 调用，将候选结果提前推送给渲染服务。
2. 渲染服务收到提前推送后，预先调用渲染信息接口，并将结果写入 Guava 本地缓存。
3. 当聚合服务返回全量召回结果时，渲染服务优先命中本地缓存，避免重复等待渲染信息调用。
4. 重点处理异步推送时序、缓存 key 设计、缓存有效期和未命中兜底，保证优化收益和结果正确性。

结果产出：推荐接口端到端耗时降低 40ms，缩短核心推荐链路响应时间。

建设请求 Mock 与调试回放能力：case 排查从小时级降低到分钟级（长期维护迭代）

角色定位：调试诊断能力核心建设者，负责请求采集、压缩存储、Trace 查询、请求回放和调试能力扩展。

背景问题：首页推荐 badcase 难以稳定复现，算法、后端、测试、前端之间联调成本高，线上问题排查依赖人工复盘，定位效率低。

核心工作：

1. 使用人群圈选画像能力，选择全部美团员工和部分重点商家客诉人群作为请求采集对象。
2. 对圈选用户的请求与推荐结果进行异步日志采集，并通过 gzip 压缩编码降低存储成本。
3. 支持基于 traceId 查询 LogCenter，回放完整推荐请求链路，复现线上请求上下文和推荐结果。
4. 扩展指定实验、圈选加白、debug 信息透出、强插供给等能力，支撑算法、测试、前端多团队联调。
5. 长期维护迭代调试能力，将原本依赖人工沟通的 case 排查流程沉淀为平台化工具。

结果产出：badcase 排查时间从小时级降低到分钟级，能力从后端团队推广到算法、测试和前端团队使用。

推动首页推荐渲染服务技术重构：需求开发效率提升 30%+（2024.12 - 2025.3）

角色定位：渲染服务重构核心开发者，负责分层架构设计、DAG 执行图编排、渲染算子拆分和注解约束机制落地。

背景问题：首页推荐渲染逻辑长期分散在业务代码中，职责边界不清，数据模型混用，代码复用性和可维护性较差，导致需求迭代成本高，也不利于 AI Coding 理解和修改代码。

核心工作：

1. 将渲染服务拆分为 IO、渲染算子、数据映射 3 层，每层设置独立数据模型，避免跨层模型腐化。
2. 设计统一路由映射框架和 DAG 执行图编排机制，将复杂渲染流程显式化、结构化。

3. 按业务域拆分数据模型，并以字段粒度拆分渲染算子，提升代码可读性、复用性和测试友好性。
4. 基于注解和框架约束算子声明、路由映射和依赖关系，减少隐式逻辑和随意扩展。
5. 通过架构重构提升代码结构清晰度，为后续 AI Coding 参与需求开发提供更稳定的代码基础。

结果产出：服务可维护性明显提升，需求开发效率提升 30%+，推荐渲染链路具备更好的模块化和 AI 友好代码基础。